



Regressão Linear

Prof. Bruno Nogueira

Agradecimentos

- ▶ Slides de aula baseados no material do prof. Andrew Ng


Regressão

- ▶ Os exemplos dos algoritmos de aprendizado de máquina que vimos até o momento aprendem modelos preditivos para problemas de classificação
 - ▶ Classes discretas
 - ▶ Conjunto contável de classes

- ▶ Alguns problemas, entretanto, requerem modelos preditivos para classes contínuas
 - ▶ **Tarefa de regressão**
 - ▶ Infinitos valores na classe


Exemplo

Tamanho da casa (em m ²)	Preço (em R\$ x 1000)
60	230
85	320
44	120
...	...
...	...
380	850



Regressão linear

Tamanho da casa (em m ²)	Preço (em R\$ x 1000)
60	230
85	320
44	120
...	...
...	...
380	850



Objetivo: encontrar a função linear que melhor se adequa aos dados

Hipóteses

► Hipótese

- Como já vimos, algoritmos de aprendizado de máquina supervisionados geram hipóteses $h(x)$ que descrevem modelos preditivos acerca dos dados

Tamanho da casa (em m ²)	Preço (em R\$ x 1 000)
60	230
85	320
44	120
...	...
...	...
380	850


x


y


$$y = f(x)$$

$$h(x) \approx f(x)$$

Regressão linear

- ▶ A hipótese na regressão linear é a função linear em função dos dados que melhor se adequa aos dados
- ▶ Em 2-D (uma variável), representa a equação de uma reta


$$h(x) = \theta_0 + \theta_1 x$$




Parâmetros da função linear

- ▶ Essa função tem dois parâmetros: θ_0 e θ_1
- ▶ A escolha dos valores destes parâmetros determinará como o modelo se comportará


$$h(x) = \theta_0 + \theta_1 x$$



$$\begin{aligned}\theta_0 &= 1,5 \\ \theta_1 &= 0\end{aligned}$$




$$\begin{aligned}\theta_0 &= 0 \\ \theta_1 &= 0,5\end{aligned}$$



$$\begin{aligned}\theta_0 &= 1 \\ \theta_1 &= 0,5\end{aligned}$$

Parâmetros da função linear

- ▶ Nos problemas de regressão, os parâmetros são escolhidos de maneira a melhor se ajustar aos dados do conjunto de treinamento, para todos os pares (x, y)
- ▶ Objetivo é minimizar a diferença entre o valor predito e o valor real dos pontos de treinamento
- ▶ Em outras palavras, o objetivo é minimizar a diferença entre $h(x)$ e y



Função de custo

- ▶ Formalmente, pode-se afirmar que o objetivo é:

$$\min_{\theta_0, \theta_1} (\text{função de custo})$$

- ▶ Geralmente, utiliza-se a função de custo dos mínimos quadrados médios (*least mean square*) ou função de erro quadrático

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

- ▶ m = número de exemplos do conjunto de treinamento
- ▶ (x^i, y^i) = i -ésimo exemplo do conjunto de treinamento
- ▶ $h(x^i) = \theta_0 + \theta_1 x^i$

Função de custo

- ▶ Logo, o objetivo da regressão linear com função de custo de erro quadrático é:


$$\min_{\theta_0, \theta_1} J(\theta_0, \theta_1) = \min_{\theta_0, \theta_1} \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

- ▶ m = número de exemplos do conjunto de treinamento
- ▶ (x^i, y^i) = i -ésimo exemplo do conjunto de treinamento
- ▶ $h(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$

Exemplo


- ▶ Por exemplo, para o problema abaixo, vamos considerar que θ_0 é igual a 0 e testar três hipóteses: $\theta_1 = 1$, $\theta_1 = 0,5$ e $\theta_1 = 0$

$$h(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$



Exemplo

► $\theta_1 = 1$



$$h(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

$$h(x^{(1)}) = 0 + 1x^{(1)} = 0 + 1 = 1$$

$$h(x^{(2)}) = 0 + 1x^{(2)} = 0 + 2 = 2$$

$$h(x^{(3)}) = 0 + 1x^{(3)} = 0 + 3 = 3$$


$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^i) - y^i)^2$$

$$J(\theta_1 = 1) = \frac{1}{2m} [(1 - 1)^2 + (2 - 2)^2 + (3 - 3)^2]$$

$$J(\theta_1 = 1) = \frac{1}{2 * 3} [0 + 0 + 0] = 0$$

Exemplo

► $\theta_1 = 0,5$



$$h(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

$$h(x^{(1)}) = 0 + 0,5x^{(1)} = 0 + 0,5 = 0,5$$

$$h(x^{(2)}) = 0 + 0,5x^{(2)} = 0 + 1 = 1$$

$$h(x^{(3)}) = 0 + 0,5x^{(3)} = 0 + 1,5 = 1,5$$


$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^i) - y^i)^2$$

$$J(\theta_1 = 0,5) = \frac{1}{2m} [(0,5 - 1)^2 + (1 - 2)^2 + (1,5 - 3)^2]$$

$$J(\theta_1 = 0,5) = \frac{1}{6} * 3,5 \approx 0,58$$

Exemplo

► $\theta_1 = 0$



$$h(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

$$h(x^{(1)}) = 0 + 0x^{(1)} = 0$$



$$h(x^{(2)}) = 0 + 0x^{(2)} = 0$$

$$h(x^{(3)}) = 0 + 0x^{(3)} = 0$$

$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^i) - y^i)^2$$



$$J(\theta_1 = 0) \approx 2,3$$

Exemplo – Função de custo



$$J(\theta_1 = 1) = 0 \quad J(\theta_1 = 0,5) \approx 0,58 \quad J(\theta_1 = 0) \approx 2,3$$


Exemplo – Função de custo



$$J(\theta_1 = 1) = 0 \quad J(\theta_1 = 0,5) \approx 0,58 \quad J(\theta_1 = 0) \approx 2,3$$

Função de custo

- ▶ Para problemas que consideram mais de uma variável, a curva da função de custo não é bidimensional



Fonte: notas de aula do Prof. Andrew Ng

Minimizando a função de custo

- ▶ Vamos, inicialmente, considerar funções de custo com 2 parâmetros, θ_0 e θ_1
 - ▶ Apenas por simplicidade
 - ▶ Podemos generalizar para quaisquer números de parâmetros

- ▶ Basicamente, temos os seguintes passos:
 1. Iniciar com algum θ_0 e θ_1
 2. Modificar θ_0 e θ_1 para tentar reduzir $J(\theta_0, \theta_1)$, até atingir um mínimo

Gradiente descendente

- Uma das maneiras de minimizar a função de custo é por meio do algoritmo do **gradiente descendente**

ALGORITMO DO GRADIENTE DESCENDENTE

Repetir até convergência:

$$\theta_j := \theta_j - \alpha * \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

(Para $j = 0$ e $j = 1$)

α = taxa de aprendizado

$\frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$ = termo de derivação

Gradiente descendente

- Atualização dos parâmetros é feita de maneira simultânea

ALGORITMO DO GRADIENTE DESCENDENTE

Repetir até convergência:

$$\theta_j := \theta_j - \alpha * \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

$$temp_0 := \theta_0 - \alpha * \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$


$$temp_1 := \theta_1 - \alpha * \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_0 = temp_0$$

$$\theta_1 = temp_1$$

Termo de derivação

- Termo de derivação reflete a inclinação da tangente ao ponto na curva da função de erro




Por simplicidade, vamos considerar apenas um parâmetro: θ_1

$$\theta_1 := \theta_1 - \alpha * \frac{d}{d\theta_1} J(\theta_1)$$


Tangente com inclinação positiva

Termo de derivação





$$\theta_1 := \theta_1 - \alpha * \underbrace{\frac{d}{d\theta_1} J(\theta_1)}_{\text{positivo}}$$

negativo



Termo de derivação




$$\theta_1 := \theta_1 - \alpha * \underbrace{\frac{d}{d\theta_1} J(\theta_1)}_{\text{negativo}}$$

positivo


Taxa de aprendizado

- ▶ α determina o quão “brusca” é a movimentação do parâmetro na curva da função de erro
- ▶ Se α é muito pequeno, então o algoritmo demora a convergir



Taxa de aprendizado

- ▶ α determina o quão “brusca” é a movimentação do parâmetro na curva da função de erro
- ▶ Se α é muito grande, o algoritmo pode não convergir



Gradiente descendente em regressão linear



ALGORITMO DO GRADIENTE DESCENDENTE

Repetir até convergência:

$$\theta_j := \theta_j - \alpha * \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

REGRESSÃO LINEAR

$$h(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

Gradiente descendente em regressão linear



$$\theta_j := \theta_j - \alpha * \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

$$\begin{aligned} \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) &= \frac{\partial}{\partial \theta_j} * \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 \\ &= \frac{\partial}{\partial \theta_j} * \frac{1}{2m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)})^2 \end{aligned}$$



$$\theta_0: j = 0 \Rightarrow \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})$$

$$\theta_1: j = 1 \Rightarrow \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) x^{(i)}$$

Gradiente descendente em regressão linear



ALGORITMO DO GRADIENTE DESCENDENTE

Repetir até convergência:

$$\theta_0 := \theta_0 - \alpha * \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha * \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) * x^{(i)}$$

- Atualização de θ_0 e θ_1 deve ser feita ao mesmo tempo.
- Gradiente descendente “batch”: olha todos os exemplos do conjunto de treinamento.

Regressão linear multivariada

- ▶ Quando consideramos mais de uma variável, precisamos fazer algumas mudanças no algoritmo do gradiente descendente

Tamanho da casa (em m ²)	Número de quartos	Número de vagas de garagem	Número de banheiros	Preço (em R\$ x 1000)
60	1	0	1	230
85	3	2	2	320
44	2	1	1	120
...	...	...	...	...
...	...	...	...	...
380	4	4	3	850

 x_1
 x_2
 x_3
 x_4
 y

Regressão linear multivariada

Tamanho da casa (em m ²)	Número de quartos	Número de vagas de garagem	Número de banheiros	Preço (em R\$ x 1000)
60	1	0	1	230
85	3	2	2	320
44	2	1	1	120
...	...	...	...	...
...	...	...	...	...
380	4	4	3	850

$$x^{(2)} = \begin{bmatrix} 85 \\ 3 \\ 2 \\ 2 \end{bmatrix} \quad x_3^{(2)} = 2$$

Regressão linear multivariada

- ▶ Com as diversas variáveis:

$$h(x^{(i)}) = \theta_0 + \theta_1 x_1^{(i)} + \theta_2 x_2^{(i)} + \dots + \theta_n x_n^{(i)}$$

- ▶ Por conveniência, vamos assumir $x_0^{(i)} = 1$

$$x^{(i)} = \begin{bmatrix} x_0^{(i)} \\ x_1^{(i)} \\ x_2^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix} \quad \theta^{(i)} = \begin{bmatrix} \theta_0^{(i)} \\ \theta_1^{(i)} \\ \theta_2^{(i)} \\ \vdots \\ \theta_n^{(i)} \end{bmatrix}$$

$$h(x^{(i)}) = \theta^T x \quad J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$

Gradiente descendente – regressão multivariada



ALGORITMO DO GRADIENTE DESCENDENTE

Repetir até convergência:

$$\theta_0 := \theta_0 - \alpha * \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha * \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) * x^{(i)}$$



ALGORITMO DO GRADIENTE DESCENDENTE MULTIVARIADO

Repetir até convergência:

$$\theta_j := \theta_j - \alpha * \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) * x_j^{(i)}$$

Gradiente descendente

- ▶ Como saber se está convergindo ou mesmo se já convergiu para o mínimo?
 - ▶ Plotar gráfico $J(\theta)$ x número de iterações
 - ▶ $J(\theta)$ deve diminuir depois de cada iteração
- ▶ Para um α suficientemente pequeno, $J(\theta)$ comprovadamente diminui a cada iteração
- ▶ Se α for muito pequeno, entretanto, convergência demora
- ▶ Solução: testar diferentes valores
 - ▶ Por exemplo: 0,001; 0,01; 0,1; 1; ...

Regressão não-linear

- ▶ Algoritmo de regressão linear é capaz de resolver apenas problemas lineares
- ▶ É possível adaptar o algoritmo para a resolução de problemas não lineares
 - ▶ Basta escolher um espaço de hipóteses não linear

$$h(x^{(i)}) = \theta_0 + \theta_1(x_1^{(i)})^2 + \theta_2(x_2^{(i)})^2 + \dots + \theta_n(x_n^{(i)})^2$$

$$h(x^{(i)}) = \theta_0 + \theta_1 x_1^{(i)} + \theta_2(x_2^{(i)})^3 + \dots + \theta_n(x_n^{(i)})^5$$

$$h(x^{(i)}) = \theta_0 + \sqrt{\theta_1 x_1^{(i)} + \theta_2(x_2^{(i)})^2 + \dots + \theta_n(x_n^{(i)})^3}$$

Truque prático: normalização dos dados

- Um problema comum em regressão multivariada é o fato de encontrarmos dados em diferentes escalas

Tamanho da casa (em m ²)	Número de quartos	Número de vagas de garagem	Número de banheiros	Preço (em R\$ x 1000)
60	1	0	1	230
85	3	2	2	320
44	2	1	1	120
...	...	...	...	...
...	...	...	...	...
380	4	4	3	850

Truque prático: normalização dos dados

- ▶ Nesses casos, uma das variáveis domina o cálculo das distâncias
- ▶ Além disso, dados com escalas muito grandes podem gerar *overflow* em variáveis no cálculo dos erros quadráticos
- ▶ Solução: normalização dos dados
 - ▶ Todos os atributos ficam no mesmo intervalo
 - ▶ Valores pequenos
 - ▶ Mantêm a distribuição dos dados

Normalização linear

- Dados no intervalo $[0, 1]$

$$l_{ij} = \frac{x_{ij} - \min(x_{.j})}{\max(x_{.j}) - \min(x_{.j})}; i = 1, \dots, m; j = 1, \dots, d$$

Normalização linear

► Dados no intervalo [0, 1]

Valor anterior do atributo j no exemplo i

Menor valor do atributo j no conjunto de dados

$$l_{ij} = \frac{x_{ij} - \min(x_{.j})}{\max(x_{.j}) - \min(x_{.j})}; i = 1, \dots, m; j = 1, \dots, d$$


Novo valor do atributo j no exemplo i

Maior valor do atributo j no conjunto de dados

Normalização por score z

- Dados com média 0 e distribuição normal

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}; i = 1, \dots, m; j = 1, \dots, d$$



Normalização por score z


► Dados com média 0 e distribuição normal

Valor anterior do atributo j no exemplo i

Valor médio do atributo j no conjunto de dados

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}; i = 1, \dots, m; j = 1, \dots, d$$

Desvio padrão do atributo j no conjunto de dados



Triola, Notas de Aula, Copyright © 2004 Pearson Education.

Exercício

- ▶ Considere os pontos (pares $(x, f(x))$): $(0, 3)$, $(5, 4)$ e $(10, 5)$. Neste problema de uma única variável, encontre a reta utilizando regressão linear que fique próxima aos pontos utilizando o método do gradiente descendente. Não se esqueça de considerar o coeficiente linear (θ_0) . Faça três iterações do método. Considere $\alpha = 0,01$ e todos os pesos iguais a 1.

Exercício II

- Considere a base de dados abaixo

Nota Disciplina 1	Nota Disciplina 2	Nota Disciplina 3	Nota Disciplina 4	Nota IA
8,5	9,0	10	10	8,0
9,0	2,0	5,5	6,0	7,5
3,5	5,0	6,0	7,0	5,0
4,0	2,0	2,5	7,5	6,6

Faça cinco iterações do algoritmo de regressão linear com gradiente descendente. Considere $\alpha = 0,01$ e todos os pesos iguais a 1. Faça o gráfico da função de custo para mostrar a evolução do erro ao longo das iterações.