



Regressão Logística


Prof. Bruno Nogueira

Agradecimentos

- ▶ Slides de aula baseados no material do prof. Andrew Ng

Regressão ou Classificação?


- ▶ Na Regressão Logística, voltamos a trabalhar com problemas de **classificação**
 - ▶ Exemplo: problema dos cogumelos
 - ▶ 0 = não comestível; 1 = comestível



Regressão ou Classificação?

- Podemos pensar em adaptar o processo de regressão linear estabelecendo um limiar (*threshold*)


$$h(x^{(i)}) = \theta^T x$$



$$\begin{aligned} \text{Se } h(x) &\geq 0,5, y = 1 \\ \text{Se } h(x) &< 0,5, y = 0 \end{aligned}$$

Regressão ou Classificação?


- ▶ Entretanto, essa não é uma boa opção
 - ▶ Falha em muitos casos
 - ▶ Além disso, pode nos dar valores de classe muito destoantes



Regressão Logística

- ▶ O objetivo da regressão logística é fornecer classes discretas: $0 \leq h(x) \leq 1$
- ▶ Para isso, utiliza da função logística ou sigmóide

$$g(z) = \frac{1}{1 + e^{-z}} \quad z \text{ é um número real}$$




$g(z)$ nunca toca em 1 ou 0 (tende ao infinito)

Regressão logística

- Trazendo a função logística para a saída do modelo, temos:

$$h(x) = g(\theta^T x) \quad \longrightarrow \quad h(x) = \frac{1}{1 + e^{-\theta^T x}}$$



Regressão logística como probabilidade

- ▶ Podemos interpretar $h(x)$ como sendo a probabilidade estimada de $y = 1$ para a entrada x
 - ▶ Por exemplo, no problema dos cogumelos, se $h(x) = 0,7$, interpretamos que há 70% de chances de ser comestível
- ▶ Formalmente:

$$h(x) = P(y = 1|x; \theta)$$


$$P(y = 0|x; \theta) + P(y = 1|x; \theta) = 1$$

$$P(y = 0|x; \theta) = 1 - P(y = 1|x; \theta)$$

Borda de decisão

$$h(x) = g(\theta^T x)$$

$$g(z) = \frac{1}{1 + e^{-z}}$$



Predizer $y = 1$ se $h(x) \geq 0,5$

$$g(z) \geq 0,5$$

$$z \geq 0$$

$$\therefore \theta^T x \geq 0$$

Predizer $y = 0$ se $h(x) < 0,5$


$$g(z) < 0,5$$

$$z < 0$$

$$\therefore \theta^T x < 0$$

Borda de decisão

- ▶ Os limiares impostos delimitam a separação entre as classes



Borda de Decisão

$$h(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

$$\theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$$

Predizer $y = 1$ se $-3 + x_1 + x_2 \geq 0$


Predizer $y = 1$ se $x_1 + x_2 \geq 3$

Borda de decisão

- ▶ Desafio é achar os parâmetros que melhor se ajustem aos dados
- ▶ Termos polinomiais tornam a borda de decisão mais complexa

$$h(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

$$\theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix} \quad \begin{array}{l} \text{Predizer } y = 1 \text{ se } -1 + x_1^2 + x_2^2 \geq 0 \\ \text{Predizer } y = 1 \text{ se } x_1^2 + x_2^2 \geq 1 \end{array}$$



Borda de decisão

- ▶ Modelos mais complexos tendem a sofrer problemas de *overfitting*
 - ▶ Alta variância
- ▶ Modelos muito simples tendem a não se adequarem aos dados e sofrer *underfitting*
 - ▶ Alto bias
- ▶ Tem-se que levar em consideração o balando bias-variância
 - ▶ Mais sobre isso mais à frente no curso
- ▶ **Navalha de Ockham**
 - ▶ Optar, dentre os modelos que mais se adequam aos dados, por aquele que tem a menor complexidade

Regressão Logística

Função de custo

- Vamos assumir um conjunto de treinamento com m exemplos

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots (x^{(m)}, y^{(m)}), \}$$

$$x \in \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ \dots \\ x_n \end{bmatrix}, x_0 = 1, y \in \{0,1\}$$

$$h(x) = \frac{1}{1 + e^{-\theta^T x}}$$


Regressão Logística

Função de custo

- ▶ Se fôssemos usar a mesma função de custo da regressão linear, teríamos:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \underbrace{\frac{1}{2} (h(x^{(i)}) - y^{(i)})^2}_{\text{Custo } (h(x), y)}$$

- ▶ Na regressão logística, $h(x) = \frac{1}{1 + e^{-\theta^T x}}$



Função não convexa.

Gradiente descendente não tem garantia de convergência

Regressão Logística

Função de custo

- Para regressão logística, definimos a função de custo como:

$$\text{Custo}(h(x), y) = \begin{cases} -\log(h(x)), & y = 1 \\ -\log(1 - h(x)), & y = 0 \end{cases}$$


Regressão Logística

Função de custo



- Para regressão logística, definimos a função de custo como:

$$Custo(h(x), y) = \begin{cases} -\log(h(x)), & y = 1 \\ -\log(1 - h(x)), & y = 0 \end{cases}$$




Regressão Logística

Função de custo



- Para regressão logística, definimos a função de custo como:

$$Custo(h(x), y) = \begin{cases} -\log(h(x)), & y = 1 \\ -\log(1 - h(x)), & y = 0 \end{cases}$$



Regressão Logística

Função de custo

- ▶ Podemos reescrever a função de custo para regressão logística de maneira unida:

$$Custo(h(x), y) = -y * \log(h(x)) - (1 - y) * \log(1 - h(x))$$

- ▶ Dessa forma, podemos reescrever a função objetivo:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m Custo(h(x^{(i)}) - y^{(i)})$$

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} * \log(h(x^{(i)})) + (1 - y^{(i)}) * \log(1 - h(x^{(i)})) \right]$$

Função logística

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} * \log(h(x^{(i)})) + (1 - y^{(i)}) * \log(1 - h(x^{(i)})) \right]$$

- ▶ Objetivo: $\min_{\theta} J(\theta)$
- ▶ Para predição: $h(x) = \frac{1}{1 + e^{-\theta^T x}}$

Como encontrar θ

- ▶ Gradiente descendente!

ALGORITMO DO GRADIENTE DESCENDENTE

Repetir até convergência:

$$\theta_j := \theta_j - \alpha * \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) * x_j^{(i)}$$

- ▶ Quase igual ao gradiente usado na regressão linear
 - ▶ O que muda é $h(x)$
 - ▶ Antes $h(x^{(i)}) = \theta^T x$
 - ▶ Agora $h(x) = \frac{1}{1 + e^{-\theta^T x}}$

Exercício Prático

- ▶ Implemente, em Python o Algoritmo de Regressão Logística utilizando o Algoritmo do Gradiente Descendente para encontrar os parâmetros
- ▶ Testar o algoritmo de Regressão Logística para resolver os problemas:
 - ▶ AND
 - ▶ OR
 - ▶ XOR