



Regularização




Prof. Bruno Nogueira

Agradecimentos

- ▶ Slides de aula baseados no material do prof. Andrew Ng




O problema de overfitting

- ▶ Vamos considerar o problema de regressão linear para predição de preços de uma casa



O problema de overfitting




- ▶ Vamos considerar o problema de regressão linear para predição de preços de uma casa



Bias x variância




- ▶ Bias (viés, em uma tradução literal) é a preferência de um algoritmo por uma hipótese em detrimento de outras
 - ▶ Todo algoritmo tem um bias indutivo
 - ▶ Bias de representação de hipótese
 - ▶ Bias de preferência
 - ▶ Bias de busca
 - ▶ Bias indutivo é utilizado para generalizar o conhecimento a partir de exemplos conhecidos
 - ▶ Limita o espaço de busca por solução
 - ▶ Sem ele, a solução pode se tornar impraticável
- ▶ Variância é a capacidade do modelo em “variar” de acordo com os dados

Bias x variância



- ▶ Alto bias limita muito o número de hipóteses
 - ▶ Neste exemplo, assumimos que os dados seguem a distribuição de uma reta
 - ▶ Não é verdade, mas o modelo não permite variações


Bias x variância



- ▶ Alta variância deixa o espaço de hipóteses muito grande
 - ▶ Neste exemplo, assumimos que os dados seguem uma distribuição de alta ordem
 - ▶ Pode, basicamente, se ajustar a quaisquer dados

Bias x variância


- ▶ Se temos muitas variáveis, então podemos ter uma função de custo mínima (zero)
 - ▶ Neste caso, se ajustou demais ao conjunto de treinamento
 - ▶ Falha na generalização da hipótese a novos exemplos




$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

Overfitting em Regressão Logística


- ▶ O mesmo pode acontecer com Regressão Logística



$$\theta_0 + \theta_1 x_1 + \theta_2 x_2$$




$$\begin{aligned} &\theta_0 + \theta_1 x_1 + \theta_2 x_2 \\ &+ \theta_3 x_1^2 + \theta_4 x_2^2 \\ &+ \theta_5 x_1 x_2 \end{aligned}$$



$$\begin{aligned} &\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 \\ &+ \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 \\ &+ \theta_5 x_1^2 x_2^3 + \dots \end{aligned}$$


Overfitting em Regressão Logística

- ▶ O mesmo pode acontecer com Regressão Logística




$$\theta_0 + \theta_1 x_1 + \theta_2 x_2$$

Underfitting
Alto bias



$$\begin{aligned} &\theta_0 + \theta_1 x_1 + \theta_2 x_2 \\ &+ \theta_3 x_1^2 + \theta_4 x_2^2 \\ &+ \theta_5 x_1 x_2 \end{aligned}$$



$$\begin{aligned} &\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 \\ &+ \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 \\ &+ \theta_5 x_1^2 x_2^3 + \dots \end{aligned}$$

Overfitting
Alta variância

Como evitar overfitting?

- ▶ Nem sempre conseguimos plotar as hipóteses para analisar seu formato
 - ▶ Geralmente tem muitos atributos
- ▶ Importante analisar o grau polinomial
- ▶ Verificar quais atributos devem permanecer
- ▶ Problemas com poucos dados e muitos atributos são altamente suscetíveis a overfitting

Como evitar overfitting?

- ▶ Duas possíveis soluções neste contexto

- ▶ Reduzir o número de atributos

- ▶ Manualmente ou algoritmos de seleção de atributos
 - ▶ Invariavelmente, leva a perda de informação, embora busque-se sempre minimizar esta perda


- ▶ **Regularização**

- ▶ Mantém todos os parâmetros, mas diminui a magnitude dos parâmetros θ
 - ▶ Funciona bem quando tem-se muitos atributos, cada um contribuindo um pouco na predição de $y = f(x)$

Otimização da função de custo para regularização

- ▶ A ideia é penalizar atributos, ajustando os parâmetros θ para um valor bem pequeno

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$




$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

Otimização da função de custo para regularização

- ▶ A ideia é penalizar atributos, ajustando os parâmetros θ para um valor bem pequeno

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + 1000 \theta_3^2 + 1000 \theta_4^2$$



θ_3 e θ_4 ficam muito próximos de 0, devido às constantes altas no processo de minimização da função de custo. Resulta na função quadrática.

$$\theta_0 + \theta_1 x + \theta_2 x^2 + \cancel{\theta_3 x^3} + \cancel{\theta_4 x^4}$$

Regularização

- ▶ Valores pequenos para parâmetros resultam em hipóteses mais simples
 - ▶ Alguns termos são praticamente desprezados
- ▶ Hipóteses mais simples são menos propensas a overfitting
- ▶ Geralmente, lidamos com muitos atributos
 - ▶ Não sabemos quais são os termos de maior ordem
 - ▶ Difícil decidir qual parâmetro diminuir
 - ▶ Solução: modificar a função de custo, incorporando um **termo de regularização**

Regularização em Regressão Linear

- Adiciona um termo ao final

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2$$



$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

Regularização

- ▶ λ é o parâmetro de regularização
 - ▶ Controla do balanço entre os dois objetivos
 - ▶ Ajustar bem ao conjunto de treinamento
 - ▶ Manter todos os parâmetros pequenos
 - ▶ Cuidado com o valor. Se muito grande, penaliza todos os parâmetros $(\theta_1, \theta_2, \dots)$
 - ▶ “Desconsidera” todos os termos da hipótese
 - ▶ Underfitting
- ▶ θ_0 não entra na regularização
- ▶ Função de custo regularizada gera uma curva de erro mais suave, resultando em melhores hipóteses

Regressão linear regularizada

- ▶ Temos uma nova função de custo

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

- ▶ Objetivo é minimizar a função de custo...

$$\min_{\theta} J(\theta)$$

- ▶ Precisamos trazer essa nova função de custo para o algoritmo do gradiente descendente

Gradiente descendente – Regressão Linear Regularizada

ALGORITMO DO GRADIENTE DESCENDENTE MULTIVARIADO

Repetir até convergência:

$$\theta_j := \theta_j - \alpha * \frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) * x_j^{(i)}$$



ALGORITMO DO GRADIENTE DESCENDENTE MULTIVARIADO REGULARIZADO

Repetir até convergência:

$$\theta_j := \theta_j - \alpha * \left[\frac{1}{m} \sum_{i=1}^m (h(x^{(i)}) - y^{(i)}) * x_j^{(i)} + \frac{\lambda}{m} \theta_j \right]$$

Gradiente descendente – Regressão Linear Regularizada

- Reescrevendo, isolando o termo de regularização...

ALGORITMO DO GRADIENTE DESCENDENTE MULTIVARIADO REGULARIZADO

Repetir até convergência:

$$\theta_j := \theta_j \left(1 - \alpha \frac{\lambda}{m} \right) - \alpha \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

Regressão Logística Regularizada

- ▶ Tínhamos a seguinte função de custo para regressão logística

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} * \log(h(x^{(i)})) + (1 - y^{(i)}) * \log(1 - h(x^{(i)})) \right]$$

- ▶ Para regularizá-la, basta adicionar um termo extra

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} * \log(h(x^{(i)})) + (1 - y^{(i)}) * \log(1 - h(x^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Gradiente descendente – Regressão Logística Multivariada

- ▶ Gradiente descendente é o mesmo

ALGORITMO DO GRADIENTE DESCENDENTE MULTIVARIADO REGULARIZADO

Repetir até convergência:

$$\theta_j := \theta_j \left(1 - \alpha \frac{\lambda}{m}\right) - \alpha \frac{1}{m} \sum_{i=1}^m (h_0(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

- ▶ O que muda é $h(x)$
 - ▶ Antes $h(x^{(i)}) = \theta^T x$
 - ▶ Agora $h(x) = \frac{1}{1 + e^{-\theta^T x}}$

Exercício

- ▶ Modifique as implementações dos algoritmos de Regressão Linear e Regressão Logística, de forma a que utilizem o procedimento de regularização